

전체 연령·65세 이상 온열질환 예측 분석 보고서

1. 분석 목적

- 기상 조건으로 전체 연령과 65세 이상 전국 일일 환자 수를 각각 예측한다.
- 두 모델의 데이터·전처리는 아래에서 비교하고, 이후 분석·평가·그래프는 모델별로 구분한다.
- 전국 단위 환자 수 예측이며 개인 발병 확률이나 외출 안전 판정 모델은 아니다.

2. 모델별 사용 데이터

| 구분    | 전체 연령 모델                                                | 65세 이상 모델                                           |
|-------|---------------------------------------------------------|-----------------------------------------------------|
| 분석 대상 | 전국 일일 전체 연령 환자 수                                        | 전국 일일 65세 이상 신고 건수                                  |
| 분석 기간 | 2022~2025년 감시기간                                         | 2022~2025년 감시기간                                     |
| 환자 원본 | 2022~2024년 연도별 XLS<br>2025년 통합 CSV                      | 2011~2025년 신고 원본 CSV<br>→ 2022~2025년·65세 이상 추출      |
| 일별 자료 | heat_illness_daily_2022_2025.csv                        | heat_illness_elderly65_daily_2022_2025.csv          |
| 학습 파일 | train_dataset.csv                                       | train_dataset_elderly65_2022_2025.csv               |
| 기상 자료 | 2022~2025년 ASOS 일자료<br>날짜별 전국 평균 8개 변수                  | 기존과 같은 ASOS 전국 평균<br>기상 변수 8개 사용                    |
| 최종 규모 | 536일 × 11열<br>연도별 134일                                  | 536일 × 11열<br>연도별 134일                              |
| 환자 합계 | 2022: 1,564 / 2023: 2,818<br>2024: 3,704 / 2025: 4,460명 | 2022: 445 / 2023: 869<br>2024: 1,174 / 2025: 1,341건 |
| 예측 정답 | total_patients                                          | elderly_patients                                    |

3. 모델별 데이터 전처리

| 처리 단계  | 전체 연령 모델                                   | 65세 이상 모델                                            |
|--------|--------------------------------------------|------------------------------------------------------|
| 환자 가공  | 2022~2024년 XLS 일별 집계와<br>2025년 통합 자료 결합    | 원본에서 연도·나이 필터 적용<br>65세 이상 3,829기록 날짜별 집계            |
| 날짜·인코딩 | 환자 CSV UTF-8-SIG<br>기상 CSV CP949; 날짜 형식 통일 | 가공 CSV UTF-8-SIG<br>날짜를 기존 기상 자료와 맞춤                 |
| 기상 처리  | 일강수량 결측치를 0으로 처리<br>8개 기상값을 날짜별 전국 평균      | 기존 학습 CSV의 기상값 8개 사용<br>전체 연령 환자 수는 가져오지 않음          |
| 날짜 결합  | 환자 자료·기상 자료의<br>공통 날짜로 병합 → 536일           | 일별 538일 → 기상값 있는 536일<br>5/17·5/19(2023년, 고령자 0건) 제외 |
| 0건·중복  | 일별 날짜 중복 여부 확인                             | 신고 없는 날짜는 신고 0건<br>환자 ID가 없어 반복행 임의 삭제 안 함           |
| 최종 확인  | 결측치 0·중복 날짜 0<br>기존 일별 환자 자료와 집계 일치        | 결측치 0·중복 날짜 0<br>추출 원본과 집계 일치, 총 3,829건              |
| 입력·정답  | X: 기상 변수 8개<br>y: 전체 연령 환자 수               | X: 기상 변수 8개<br>y: 65세 이상 신고 건수                       |
| 출처 차이  | 기존 집계는 공식 연보 합계와 일치                        | 새 원본은 2022~2024년 연보와<br>불일치. 원인 미확인·강제 보정 안함         |

※ 일강수량의 결측치를 0으로 간주한 것은 현재 전처리 방식이며, 미관측과 무강수의 구분은 추가 검토가 필요하다.  
입력 변수: 평균·최저·최고기온, 일강수량, 평균 풍속, 평균 상대습도, 합계 일조시간, 합계 일사량.


모델 1. 전체 연령 - EDA·학습·평가

4. 전체 연령 EDA - 현황과 분포

| 연도   | 분석 일수 | 환자 합계(명) | 일평균(명) |
|------|-------|----------|--------|
| 2022 | 134   | 1,564    | 11.7   |
| 2023 | 134   | 2,818    | 21.0   |
| 2024 | 134   | 3,704    | 27.6   |
| 2025 | 134   | 4,460    | 33.3   |


- 분석 기간의 환자 합계는 2022년 1,564명에서 2025년 4,460명으로 증가했다. 이 자료만으로 증가 원인을 기온 변화 하나로 단정할 수는 없다.

그림 1. 연도별 일일 온열질환자 수 변화



- 각 연도를 감시기간의 첫날부터 나란히 비교했다. 가로축은 실제 달력 날짜가 아니라 감시기간 내 순서이며, 일부 날짜에 환자 수가 크게 집중된다.


그림 2. 일일 온열질환자 수 분포



- 일평균 23.4명, 중앙값 9명, 최댓값 259명이다. 낮은 환자 수에 날씨가 많이 몰리고 오른쪽 꼬리가 긴 분포다. 세로축은 환자 합계가 아닌 날짜 수다.


## 5. 전체 연령 EDA - 기상 조건과의 관계

그림 3. 최고기온과 전국 일일 온열질환자 수



- 날짜별 전국 평균 최고기온이 높을수록 환자 수가 많은 경향이 나타난다. 같은 기온에서도 환자 수의 차이가 커 기온만으로 모든 변동을 설명하지는 못한다.

그림 4. 기상 변수와 환자 수의 상관계수



- 최고기온(0.722), 평균기온(0.672), 최저기온(0.548) 순으로 양의 상관관계가 크다. 일조시간·일사량도 양의 상관을 보이며, 상대습도의 선형 상관은 약하다.

※ 상관계수는 선형 관계이며 인과관계나 모델 중요도와 다르다. 전국 평균은 지역별 차이를 가릴 수 있다.

※ 아래 성능과 그래프는 전체 연령 모델에 해당한다. 차이가 가려질 수 있다.

6. 전체 연령 모델 학습·평가 및 중요도


- Decision Tree와 Random Forest를 비교한 뒤, 5겹 교차검증을 사용하는 GridSearchCV로 랜덤포레스트를 튜닝하였다. 아래 표는 학습 데이터와 테스트 데이터의 평가 결과를 구분한 것이다.

| 구분        | 평가 대상 데이터                           | MAE(명) | RMSE(명) | R <sup>2</sup> |
|-----------|-------------------------------------|--------|---------|----------------|
| 학습 평가     | 무작위 분리의 학습 데이터 428일                 | 6.056  | 12.298  | 0.853          |
| 무작위 테스트   | 무작위 분리의 테스트 데이터 108일                | 9.700  | 14.871  | 0.846          |
| 연도 분리 테스트 | 2022~2024년 402일 학습 후, 2025년 134일 평가 | 13.128 | 23.960  | 0.686          |

- 학습 R<sup>2</sup>는 0.853이며, 무작위 테스트 R<sup>2</sup>는 0.846이다. 무작위 테스트의 MAE는 약 9.7명으로, 실제 환자 수와 예측값의 절대오차가 평균 약 9.7명이었다.
- 연도 분리 테스트에서는 R<sup>2</sup>가 0.686으로 낮아지고 MAE가 약 13.1명으로 커졌다. 새로운 연도에 대한 추가 검증이 필요하다. R<sup>2</sup>는 정확도가 아니라 결정계수이다.

\* 최종 설정  
: 나무 100개, 최대 깊이 7, 최소 분할 샘플 8, 최소 리프 샘플 5, max\_features="sqrt", random\_state=42.

그림 5. 최종 랜덤포레스트 기상 변수 중요도



- 최고기온 36.3%, 평균기온 27.4%, 최저기온 17.0%로 기온 변수의 중요도 합계는 약 80.7%다. 중요도는 모델 내부 지표이며 환자 발생의 인과적 기여율이 아니다.

## 7. 전체 연령 모델 - 데이터 파일과 연도별 평가

원본: heat\_illness\_2022.xls, heat\_illness\_2023.xls, heat\_illness\_2024.xls


2025년 원본 가공 자료: heat\_illness\_2025\_unified.csv

일별 환자 수: heat\_illness\_daily\_2022\_2025.csv / 학습: train\_dataset.csv

모델: model/saved/heat\_patient\_model.pkl / 기상 입력 변수 8개

기상 원본은 data/raw의 2022·2023·2024년 폴더와 2025년 ASOS CSV를 사용한다.

### 그림 6. 전체 연령 모델의 2025년 실제값·예측값



- 2022~2024년 학습 → 2025년 평가:  $R^2$  0.686, MAE 13.128명, RMSE 23.960명.
- 기존 연도 평가 코드의 고정 설정으로 재현했다. 저장된 주 모델을 덮어쓰지 않았다.
- 설정이 전체 연도의 무작위 분리 과정에서 선택되었으므로 튜닝까지 독립된 연도 검증은 아니다.
- 무작위 평가와 연도 평가 결과를 함께 제시하고, 다른 연도에서 성능이 낮아지는 한계를 기록한다.

모델 2. 65세 이상 전국 일일 온열질환 신고 건수 예측

1. 고령자 현황 분석 결과

| 연도   | 분석 일수 | 신고 합계(건) | 일평균(건) | 최대(건) |
|------|-------|----------|--------|-------|
| 2022 | 134   | 445      | 3.32   | 28    |
| 2023 | 134   | 869      | 6.49   | 58    |
| 2024 | 134   | 1,174    | 8.76   | 76    |
| 2025 | 134   | 1,341    | 10.01  | 89    |

- 총 3,829건이며 일평균은 7.14건이다. 데이터 출처와 전처리는 앞의 모델별 비교표에 정리하였다.
- 새 원본과 공식 연보의 집계 차이는 미해결이며, 공개 CSV 신고 건수를 기준으로 해석한다.
- \* 자료 출처: <https://www.data.go.kr/data/15149889/fileData.do>

2. 고령자 모델 - 학습 및 평가 결과

- 학습 자료 안에서 GridSearchCV(cv=5)로 R²가 높은 설정을 선택하였다.

| 구분        | 평가 대상 데이터                           | MAE(건) | RMSE(건) | R²    |
|-----------|-------------------------------------|--------|---------|-------|
| 학습 평가     | 무작위 분리 학습 428일                      | 1.626  | 3.149   | 0.917 |
| 무작위 테스트   | 무작위 분리 테스트 108일                     | 3.209  | 4.917   | 0.837 |
| 연도 분리 테스트 | 2022~2024년 402일 학습<br>2025년 134일 평가 | 4.174  | 7.687   | 0.687 |

- 주 모델은 학습 R² 0.917, 테스트 R² 0.837이며, 테스트에서 하루 평균 절대오차는 3.209건이다.
- 연도 평가에서는 R² 0.687, MAE 4.174건으로 새 연도 예측의 오차가 더 크게 나타났다.

\* 교차검증 비교

| 실험            | 모델                        | 교차검증 R² |
|---------------|---------------------------|---------|
| 무작위 학습 분할 내부  | RandomForestRegressor     | 0.739   |
| 2022~2024년 내부 | RandomForestRegressor     | 0.480   |
| 2022~2024년 내부 | GradientBoostingRegressor | 0.373   |

- 두 연도 실험 모델은 같은 자료·분할에서 비교했으며, 탐색한 후보에서는 랜덤포레스트가 더 높았다.
- 무작위 학습 분할과 연도 분리 실험은 조건이 다르므로 교차검증 점수를 직접 비교하지 않는다.

고령자 모델 설정 및 저장


| 항목           | 고령자 주 모델                 | 연도 평가용 모델                    |
|--------------|--------------------------|------------------------------|
| 학습 코드        | model_train_elderly65.py | model_year_test_elderly65.py |
| 학습 범위        | 2022~2025년 무작위 428일      | 2022~2024년 전체 402일           |
| 트리 개수        | 100                      | 200                          |
| 최대 깊이        | 10                       | 20                           |
| 최소 분할 샘플     | 5                        | 3                            |
| 최소 리프 샘플     | 2                        | 1                            |
| max_features | sqrt                     | sqrt                         |
| random_state | 42                       | 42                           |
| 저장 여부        | 모델·기상 컬럼 목록 저장           | 별도 연도 평가 실험용                 |

- \* 저장 파일: model/saved/heat\_patient\_elderly65\_model.pkl
- 저장된 주 모델은 전체 536일 재학습 모델이 아니라 무작위 학습 분할 428일로 학습한 모델이다.
- 주 모델의 재로드 예측 및 연도 평가 고정 설정의 수치를 재확인하였다. 교차검증 점수는 실행 기록이다.
- 2025년 결과를 확인한 뒤 추가 실험을 진행했으므로 연도 평가는 완전히 독립된 최종 검증이 아니다.
- R<sup>2</sup>는 정확도가 아닌 결정계수이며, 평균 오차가 모든 날짜의 오차 범위를 뜻하지 않는다.




3. 고령자 EDA - 날짜별 변화와 분포

그림 1. 연도별 일일 고령자 신고 건수 변화



- 연도별 최대 일일 신고는 28·58·76·89건이었다. 여름철 일부 날짜에 신고가 집중되며, 연도 사이 빈 구간은 감시 기간 밖이므로 0건으로 해석하지 않는다.


그림 2. 일일 고령자 신고 건수 분포



- 일평균 7.14건, 중앙값 3건, 최댓값 89건이다. 낮은 신고 건수의 날짜가 많고 급증한 날짜는 드물어 오른쪽 꼬리가 길다. 드물다는 이유만으로 큰 값을 삭제하지 않는다.


#### 4. 고령자 EDA - 기상 조건과의 관계

그림 3. 전국 평균 최고기온과 고령자 신고 건수



- 기온이 높은 구간에서 신고 건수가 많아지는 비선형 경향이 보인다. 비슷한 기온에서도 신고 건수가 달라 기온만으로 변동을 모두 설명할 수는 없다.


그림 4. 기상 변수와 고령자 신고 건수의 상관계수



- 최고기온 0.684, 평균기온 0.629, 최저기온 0.506 순으로 양의 상관이 크다. 상관관계가 인과관계를 뜻하지 않으며 습도의 약한 선형 상관을 건강 영향이 없다는 뜻으로 해석하지 않는다.

## 5. 고령자 EDA - 저장 모델의 변수 중요도

그림 5. 고령자 랜덤포레스트의 기상 변수 중요도




- 최고기온 36.0%, 평균기온 22.9%, 최저기온 17.3%로 세 기온 변수 합계는 약 76.2%다. 이는 나무 분할의 불순도 감소 기반 중요도이며 인과적 기여율이나 정확도가 아니다.
- 중요도 그래프는 무작위 분리로 학습·저장한 고령자 주 모델을 불러와 작성했다. 중요도 추출과 별도로 저장 모델의 predict 실행도 확인하였다.

## 6. 고령자 모델 - 결론 및 구현 현황

- 기존 전체 연령 모델을 보존하고, 65세 이상 신고 건수 예측용 랜덤포레스트를 별도로 학습·저장하였다. 고령자 주요 EDA 5종을 완료했다.
- 무작위 테스트에서는  $R^2$  0.837이었지만 새로운 연도에서는 성능 저하와 큰 오차가 관찰됐다. 두 결과와 데이터 출처의 불일치를 함께 보고한다.
- 전체 연령과 65세 이상 모델에 각각 데이터 분위수 기반 4단계 예측 등급을 적용하였다.  
이 등급은 프로젝트 내부의 상대 기준이며 의학적으로 검증된 위험 기준이 아니다.
- Streamlit과 Next.js 화면에서 두 모델을 선택하고 전국 하루 평균 및 선택 지역·시간대의 참고 예측을 제공한다.  
고령자는 전체 연령에 포함되므로 두 예측값을 합산하지 않으며, 두 모델은 별도로 해석한다.
- Open-Meteo 예보를 연결했고 기상청 API 키가 있으면 폭염특보를 함께 조회한다. 개인 발병 확률이나 외출 안전 판정으로 제공하지 않는다.

7. 고령자 모델 - 2025년 실제값·예측값

그림 6. 2022~2024년으로 학습한 고령자 모델의 2025년 예측



- 환자 증가·감소 흐름은 일부 따라가지만 급증 구간의 과소 예측과 일부 기간의 과대 예측이 보인다.
- 이 그림은 연도 평가용 모델의 결과이며, 성능과 설정은 앞의 학습·평가 표를 참고한다.

## 서비스 구현. Streamlit·Next.js

### 1. 공통 예측 흐름

- 사용자는 전체 연령 또는 65세 이상 모델과 날짜·지역·외출 시간·체류시간을 선택한다.
- Open-Meteo 예보를 전국 대표 지점의 하루 평균과 선택 지역의 외출 시간대 평균으로 각각 가공한다.
- 저장 모델의 weather\_columns 순서에 맞춰 8개 기상 변수를 입력하고 예상 환자 수와 4단계 등급을 계산한다.
- 외출 안내는 모델 결과와 시간대 규칙을 결합한 참고 정보이며 의료 진단이나 안전 보증이 아니다.

### 2. Streamlit 앱

- Python 기반 분석형 화면으로 예측 결과, 모델 정보, 데이터 분석을 세 개 탭으로 제공한다.
- 사이드바에서 조건을 입력하며 전체 연령·65세 이상 모델의 성능과 학습 자료를 같은 화면에서 비교한다.

#### 그림 1. Streamlit 예측 화면

The image shows a Streamlit web application interface for predicting heatstroke patients. The interface is dark-themed and consists of a sidebar on the left and a main content area on the right.

**Sidebar (Left):**

- 예측 정보 입력** (Prediction Information Input)
- 예측 대상** (Prediction Target): A dropdown menu with "전체 연령" (All Ages) selected.
- 예측 날짜** (Prediction Date): A date input field showing "2026 / 09 / 06".
- 외출 지역** (Outing Area): A dropdown menu with "서울" (Seoul) selected.
- 외출 시작 시각** (Outing Start Time): A time input field showing "9시" (9 AM).
- 야외 체류시간(분)** (Outdoor Stay Time (min)): A numeric input field with a value of "60" and minus/plus buttons.
- 예측하기** (Predict) button: A red button at the bottom of the sidebar.

**Main Content Area (Right):**


- 온열질환자 수 예측** (Heatstroke Patient Count Prediction): The main title.
- 기상 정보를 입력하면 예상 환자 수를 확인할 수 있습니다.** (After entering weather information, you can check the expected number of patients.)
- 예측 결과** (Prediction Result): A tab that is currently active, with "모델 정보" (Model Information) and "데이터 분석" (Data Analysis) as other tabs.
- 예측 결과** (Prediction Result): A section header for the results.
- 사이드바에서 조건을 선택한 후 '예측하기' 버튼을 눌러주세요.** (Please select conditions in the sidebar and click the 'Predict' button.)

**Top Right:** A "Deploy" button and a menu icon.

3. Next.js 웹사이트

- Next.js API Route가 Python 연결 스크립트를 실행해 기존 모델·데이터·weather\_api.py를 재사용한다.
- 예측 조건과 결과를 한 화면에 구성하고 데스크톱과 모바일 환경에 대응하는 반응형 UI를 제공한다.

그림 2. Next.js 예측 웹사이트



## 4. 구현 구조와 검증

- 공통 Python 계층: 저장 모델 로드, 기상 예보 수집·단위 변환, 위험 등급, 외출 안내를 담당한다.
- Streamlit 계층: app.py가 Python 함수를 직접 호출한다.
- 웹 계층: Next.js API Route → web/scripts Python 연결 스크립트 → 공통 Python 계층 순서로 호출한다.
- Python 3.13 환경에서 모델·분석 데이터 로드를 확인했고 Next.js는 npm ci, ESLint, 프로덕션 빌드를 통과했다.
- 기상청 폭염특보는 .streamlit/secrets.toml의 KMA\_API\_KEY가 있을 때 조회하며, 키가 없어도 앱과 분석 화면은 실행된다.

## 5. 결론 및 한계

- 두 저장 모델과 두 사용자 화면을 연결해 예측·설명·EDA 결과를 확인할 수 있는 서비스 형태로 확장하였다.
- 모델은 전국 평균 기상과 전국 신고 환자 수의 관계를 학습하므로 선택 지역의 실제 환자 수를 직접 예측하지 않는다.
- 외출 시간대 결과는 선택 지역 기상값을 기존 전국 모델에 넣은 참고값이며 개인별 건강 상태를 반영하지 않는다.
- 연도 분리 평가에서 성능 저하가 확인되었으므로 새 연도 자료를 이용한 지속적인 재검증이 필요하다.